

PDF 差分検出システム 仕様書

バージョン 2.0 (エンタープライズ大規模拡張版)

次世代プラットフォームアーキテクチャチーム

2026 年 8 月 8 日

1. プロジェクト概要

本ドキュメントは、次世代 PDF ビュワーにおける**自動差分検出エンジン**の大規模改定仕様 (v2.0) を定義するものです。本システムは、ユーザーが指定した 2 つの PDF ドキュメントを比較し、テキスト・段落構造・高度な表レイアウト・および各種図表 (SVG/Raster 画像) の変更箇所をミリ秒単位で判定し、GUI 上で鮮明なカラーハイライト表示します。

バージョン 2.0 では、新たに**並列分散 Worker 構成**および**GPU/NPU アクセラレーション**を導入し、数百ページに及ぶ大型技術文書や契約書の全自動差分判定をサポートします。

2. システム性能および動作仕様比較


以下に、過去バージョンから v2.0 への性能進化および仕様比較を示します。

評価項目	v1.0 (初期版)	v1.1 (改訂版)	v2.0 [今回仕様]
対応ファイル形式	PDF (v1.4 - v2.0)	PDF, XPS	PDF, XPS, EPUB, CBZ
最大比較ページ数	100 ページ	500 ページ	5,000 ページ (大容量対応)
1 ページ平均処理速度	1.50 秒	0.40 秒	0.05 秒 (30 倍高速化)
差分検出精度	95.0 %	99.8 %	99.99 % (サブピクセル精度)
対応動作環境	macOS, Win11	macOS, Win11, Ubuntu	macOS, Win11, Linux, Cloud Worker

3. エンタープライズアーキテクチャ

以下に、Auto-Scaling および Multi-Region 冗長化に対応した最新の分散アーキテクチャ構成図を示します。

システム構成図 v2.0 (エンタープライズ分散構成)



最大スループット: 50,000 req/sec (Auto-Scaling有効)

Figure 1: システムアーキテクチャ図 (v2.0 分散構成)

4. パフォーマンス検証結果

各バージョンにおける 1 ページあたりの判定処理速度のベンチマーク比較結果は以下の通りです。





Figure 2: 処理速度ベンチマーク比較

5. 差分解析パイプラインと処理フロー

本システム内部では、入力された 2 つの PDF を並列に構文解析し、レイアウト抽出とベクトル/ラスター比較をマルチステージで実行します。

PDF差分解析パイプライン 処理フロー



GPUメモリマッピングにより、ステップ2～4は完全インメモリで連携動作します

Figure 3: 差分解析パイプライン 処理フロー

以下は各処理ステージの詳細仕様です：

1. **Step 1 (PDF 構文解析)**: オブジェクトツリーおよびフォントエンコーディングテーブルを読み込み、内部ベクトル表現に変換します。
2. **Step 2 (レイアウト分離)**: テキストブロック、表要素、およびインライン画像を自動判定し、各要素のバウンディングボックスを算出します。
3. **Step 3 (ハイブリッド差分判定)**:
 - ・ **テキスト判定**: レベンシュタイン距離およびトークン類似度アルゴリズムを適用。
 - ・ **画像判定**: Perceptual Hash (pHash) および SSIM (構造的類似性) アルゴリズムによる多角比較。
4. **Step 4 (GUI 即時描画)**: Tauri GUI レイヤーに対して GPU 共有メモリ (Zero-Copy) 経由で差分座標データをストリーミング転送します。

6. 運用上の注意点とセキュリティ規定

1. **並列処理モード**: 1,000 ページを超えるドキュメントの判定時は、設定パネルより「分散クラウド Worker」を有効にしてください。
2. **暗号化 PDF の取り扱い**: AES-256 で保護されたドキュメントは、HSM (ハードウェアセキュリティモジュール) 連携による暗号化解除を行います。
3. **監査ログおよび出力**: 全ての差分判定結果は、改ざん防止ハッシュが付与された PDF レポートおよび JSON/CSV データとして出力可能です。